

Manutenção Prescritiva em Ativos Rotativos

Denise do Rocio Maciel

Case Técnico — Processo Seletivo 02198/2026 FIESC

Analista em Pesquisa de Desenvolvimento Tecnológico e Inovação Pleno

[Desenvolvedor Full Stack - Pleno - IA e Python](#)

>> Repositório principal:

https://github.com/denise25maciel/projeto_manutencao_preditiva_prescritiva.git

>> Repositório secundário (utilizado para aprimorar modelo de

ML): https://github.com/denise25maciel/projeto_manutencao_preditiva_prescritiva_classificacao.git

Sumário

1. Problema
2. Objetivo
3. Fontes de dados
4. Módulo 1 — Análise de dados
5. Módulo 2 – Preparação dos dados
- 5.1 Adaptar base de dados para o formato do evento
6. Módulo 3 — Machine learning
7. Módulo 4 – Recuperação de informação

1. Problema

Uma fábrica tem motores girando. Neles há um sensor que mede **vibração**, a cada 2 segundos. Quando um rolamento começa a se desgastar, ou quando o eixo sai do alinhamento, a vibração muda de jeito — muito antes de a máquina parar.

2. Objetivo

Desenvolver um pipeline completo de Inteligência Artificial para uma solução de Manutenção Prescritiva, capaz de analisar novos registros provenientes dos sensores, identificar padrões semelhantes no histórico operacional e, a partir da recuperação de informações em documentos técnicos da empresa, apoiar a identificação e correção de problemas nos equipamentos. A proposta vai além de simplesmente prever falhas: busca utilizar dados históricos, busca por similaridade e conhecimento documental para recomendar ações de inspeção, manutenção ou correção

O objetivo é responder duas perguntas, nesta ordem:

3. Fontes de dados

Temos **duas fontes de informação, de naturezas completamente diferentes**:

FONTE A — os números

166.796 linhas de medida
26 colunas
coleta entre 05 e 06/26


FONTE B — os manuais

6 documentos em português
"Verifique o alinhamento com
relógio comparador..."
Seções numeradas, 168 trechos

A fonte A, disponibilizada em CSV tem uma coluna especial, **fault**, em que o operador anotou à mão o que estava sendo testado: **rolamento_inner**, **desbalanceado_2**, **normal**, **new_cocked_rotor**, entre outros. São **151 valores distintos** — porque o mesmo defeito foi escrito de vários jeitos, inclusive com erros de digitação.

2.1 Conexão entre as fontes de dados

As fontes de dados se comunicam através da coluna **fault**:



*A ponte única entre os números e os manuais: a coluna **fault**.*

Importante:

Apesar de a coluna “fault” conter as falhas as mesmas não estavam padronizadas e havia erros devido a preenchimento manual. Por consequência a conexão foi gerada através de processamento de dados. Foi

gerado arquivo YAML que indica famílias de erro, erros similares, e a respectiva coluna na base de dados. Atualmente o arquivo tem 16 famílias que agrupam as 151 falhas encontradas. Duas famílias estão marcadas como **sem documento** (**ventoinha** e **falta_fase**).

4. Módulo 1 — Análise de dados

Através da análise de dados informações significativas foram identificadas:

- Necessidade de transformar a base de dados para que representassem os conjuntos de séries temporais a serem analisados
- O arquivo não está ordenado por data
- Dados de série temporal precisariam ser segmentados devido longos períodos sem registro dentro de uma mesma falha
- Quantidade de defeitos poderia ser agrupada, gerando as aqui denominadas “famílias de falha”
- Mil leituras com o mesmo horário. Há um bloco de 1.000 leituras de rolamento_outer_2 todas carimbadas com 2026-06-03 15:28:49.341658. Os dados de vibração são reais.
- colunas com o mesmo dado, mas com unidades de medida diferentes

5. Módulo 2 — Preparação dos dados



Passo a passo preparação dos dados

1. Dados de data e tempo foram convertidos para que o trabalho com eles pudesse ser realizado.
2. Algumas colunas foram removidas porque representavam o mesmo dado em diferente unidade de medida.
3. Ordenar dados, os mesmos não vieram em conformidade com ordem cronológica.
4. Tirar rótulo sem catálogo é o procedimento que retira falhas caso elas não pertençam a nenhuma família. No momento, foi criada apenas como segurança para o caso de recebimento de arquivos inconsistentes
5. Em tirar evento curto, eventos com quantidade muito pequena de registros são removidos
6. Tratar nulo evita erros no algoritmo de ML. Na base de dados não havia dado nulo, no entanto, devido à importância, a função foi mantida.

5.1 Adaptar base de dados para o formato do evento

O rótulo **rolamento_inner** tem **17.712 leituras** no arquivo. Uma análise simplista interpretaria que há 17 mil ocorrências de eventos de falha. Na realidade, o que ocorre é que um evento de falha é representado por n linhas do arquivo. Logo, foi necessário adicionar pré-processamento.

Nas primeiras fazes testou-se segmentar as falhas como vieram na base de dados, os resultados do algoritmo de classificação não foram bons. Repetiu-se o processo agrupando por falha e depois organizando em ordem cronológica e vice-versa. Ao longo das análises de dados observou-se que boa parte dos registros de falha possuíam menos que 500 eventos de registro, valor muito abaixo dos demais. P

Por consequência foram realizados testes de segmentação dos registros de falha em valores menores. Especificamente 15,30, 90, 180 e 360. Não houve grande diferença nas métricas e optou-se por definir o tamanho do evento de análise em 180. Valor escolhido devido a bom resultado nas métricas de ML e maior comprimento de comparação.

Após a realização da segmentação, foram calculadas as estatísticas abaixo para cada segmento:


Estatística	Responde	Por que ela
mediana	Em que patamar o trecho ficou	Robusta ao pico isolado — e em kurtosis o pico isolado é frequente, então a média enganaria
desvio	O quanto oscilou em torno do patamar	Separa o trecho estável do agitado, mesmo com a mesma mediana
inclinação	Se estava subindo ou caindo	A única que observa a ordem. Sem ela, embaralhar o trecho não mudaria nenhum número — e um defeito que se agrava seria igual a um que estabilizou
amplitude	Distância entre o maior e o menor	O extremo do trecho
p90 – p10	A mesma ideia, sem os 10% das pontas	Ao lado da amplitude, separa “oscilou o tempo todo” de “teve um pico e voltou”

16 colunas × 5 estatísticas = 80 números por exemplo.

Os resultados desses cálculos foram enviados ao modelo de Machine Learning que será detalhado no próximo módulo. Logo, o modelo não tem acesso às séries temporais de falha, mas sim a estatísticas resultantes de seus segmentos.

6. Módulo 3 — Machine learning

O Modelo de Machine Learning implementado objetiva a classificação das séries temporais a partir de um dado conjunto de valores. O pipeline de Machine learning aplicado é composto por 6 etapas descritas na figura abaixo:



De leituras de sensor a exemplos de treino, em seis passos.


O modelo foi resolvido com um algoritmo de Random Forest de 400 árvores. A acurácia final foi de 92% chegando a valores mais altos quando a segmentação de dados era menos. Apesar da acurácia elevada, foi realizado teste adicional segmentando a base de treino e teste por divisão dos tipos de falha. Nesse cenário, a acurácia foi reduzida para 44%. O fato pode representar perda na capacidade de identificação ou também refletir que a divisão do conjunto treino e teste escolhida não permitiu a generalização dos dados. Para esclarecer esse conflito e aprimorar os resultados, alinhamento com os Stakeholders faz-se necessário.



As duas formas de corte.

7. Módulo 4 – Recuperação de informação

A figura abaixo apresenta o fluxo de consulta aos dados e documentos. Guardrail foram aplicados com o objetivo de que apenas o conteúdo do manual fosse apresentado. Eles são descritos em sequência.



Fluxo do Módulo de conversação

É importante citar que o modelo de linguagem não participa da consulta porque uma busca por semelhança **nunca volta vazia**, e um modelo de linguagem também não. Peça a qualquer um dos dois que encontre o procedimento de uma falha que não tem procedimento nenhum, e os dois devolverão o item menos diferente, com a mesma segurança com que devolveriam o certo. Não há, na resposta, nada que distinga "achei" de "não achei, mas isto aqui se parece". É por isso que a pergunta *"existe manual para esta falha?"* é um SELECT no `fault_map.yaml`, um arquivo curado à mão: uma consulta exata pode devolver lista vazia, e lista vazia é a única forma honesta de dizer não sei. Quando o modelo entra depois dessa consulta, a diferença é grande —não está procurando o que responder, está redigindo o que já foi encontrado, e o pior caso deixa de ser uma prescrição errada com fonte plausível e passa a ser um texto mal escrito.

Abaixo, segue relação dos principais guardrails presentes no sistema

ID	Pergunta que faz	Como	Se falhar
G0	O JSON recebido faz sentido?	Confere campos obrigatórios e faixas físicas	Rejeita a entrada
G1	A evidência aponta um manual?	Margem e concentração do ranking	Mostra a lista, o técnico escolhe
G2	É defeito, ou só um estado normal?	SELECT no <code>fault_map.yaml</code>	Encerra o fluxo prescritivo
G3	Essa família tem manual?	SELECT no <code>fault_map.yaml</code>	"Sem documentação"
G4	Os trechos recuperados servem?	Score de similaridade $\geq 0,15$	Trata como G3
G5	A citação existe mesmo?	Regex na resposta × trechos enviados	Regenera ou degrada

8.Conclusão

A solução desenvolvida demonstra a aplicação integrada de técnicas de Inteligência Artificial, análise de dados e recuperação de conhecimento para a construção de uma abordagem de Manutenção Prescritiva. A partir dos dados provenientes dos sensores, foi estruturado um processo capaz de analisar novos eventos, identificar padrões semelhantes no histórico operacional e relacioná-los às informações disponíveis na documentação técnica. Essa integração permite não apenas reconhecer comportamentos associados a problemas já registrados, mas também utilizar o conhecimento documentado para auxiliar na definição de possíveis ações de inspeção, manutenção e correção. Dessa forma, a abordagem desenvolvida atende ao propósito central do estudo de ampliar a capacidade de resposta da manutenção, transformando dados operacionais e conhecimento histórico em informações que podem apoiar a tomada de decisão das equipes técnicas. Por fim, cabe ressaltar que aprimoramentos de funcionalidades adicionais compatíveis com o objetivo inicial podem aprimorar os resultados. Além disso , alinhamento com os stakeholders referente ao comportamento das séries temporais é recomendado.

9. Glossário

Termo	Em português claro
Acurácia	Fração de acertos. Só significa algo comparada a uma referência
Chunk / trecho	Um pedaço de manual, aqui uma seção numerada. São 168
Cosseno (similaridade)	Número de -1 a +1 que mede o quanto dois textos falam da mesma coisa
Embedding	Lista de 384 números que representa o <i>sentido</i> de um texto
Evento (ou episódio)	Uma vez em que a máquina foi medida com o mesmo defeito, na mesma rotação. São 526
F1 macro	Média de acerto dando o mesmo peso a cada família , inclusive as raras
Fold	Uma das 5 rodadas da validação cruzada
Guardrail	Trava de segurança implementada em código
Inflação	A distância entre a acurácia falsa e a honesta. Aqui, 48 pontos
Janela	Bloco de 50 leituras consecutivas dentro de um evento
kNN	<i>k-nearest neighbors</i> : acha os k eventos históricos mais parecidos
LLM	<i>Large Language Model</i> — o modelo de linguagem
Prescritiva	Manutenção que prevê a falha e diz o que fazer , citando a fonte
RAG	Recuperar o texto relevante primeiro, e só então pedir ao modelo que escreva
Random Forest	400 árvores de decisão votando
Regime de operação	rpm e temperatura: condição em que a máquina roda, não sintoma
Validação cruzada	Cortar em 5 partes, treinar em 4, testar em 1, repetir e tirar a média
Vazamento (<i>leakage</i>)	O modelo acessar informação que não teria na vida real, e acertar por causa dela
